

Endterm Task (UTS)

Aletha Tanisha (2106722770)

December 20, 2024

1 Pendahuluan

Deteksi tumor otak merupakan salah satu tantangan besar dalam dunia medis karena sifatnya yang kompleks serta dampak signifikan yang ditimbulkannya terhadap kualitas hidup pasien. Tumor otak, baik yang bersifat jinak maupun ganas, dapat memengaruhi berbagai fungsi vital tubuh, seperti kemampuan motorik, kognitif, dan fungsi sensorik, tergantung pada lokasi dan ukuran tumor. Selain itu, deteksi dini sering kali sulit dilakukan karena gejala awal yang muncul biasanya tidak spesifik, seperti sakit kepala, mual, atau gangguan penglihatan, yang juga bisa disebabkan oleh kondisi medis lainnya. Hal ini menyebabkan banyak kasus tumor otak baru terdiagnosis pada tahap yang sudah lanjut, di mana peluang untuk keberhasilan pengobatan menurun secara signifikan. Oleh karena itu, diagnosis yang cepat, akurat, dan efisien menjadi kunci untuk meningkatkan peluang kesembuhan pasien.

Seiring dengan kemajuan teknologi dalam bidang pencitraan medis, alat seperti *Magnetic Resonance Imaging* (MRI) dan *Computed Tomography* (CT) telah menjadi standar dalam mendeteksi tumor otak. MRI, misalnya, mampu memberikan informasi detail mengenai struktur otak, jaringan lunak, dan anomali yang mungkin mengindikasikan keberadaan tumor. Namun, meskipun teknologi ini sangat membantu, analisis citra medis sering kali memerlukan keahlian tinggi dari seorang radiologis untuk mengidentifikasi dan menginterpretasi hasil dengan tepat. Proses ini tidak hanya memakan waktu tetapi juga rentan terhadap kesalahan manusia, terutama dalam kondisi di mana volume data yang harus dianalisis sangat besar. Faktor ini dapat menghambat proses diagnosis yang cepat dan efisien, yang sangat penting dalam menangani kasus tumor otak.

Dalam beberapa tahun terakhir, perkembangan *Artificial Intelligence* (AI), khususnya dalam bidang deep learning, telah membuka peluang baru dalam analisis citra medis. Salah satu pendekatan yang paling menjanjikan adalah penggunaan *Convolutional Neural Network* (CNN), sebuah jenis model *deep learning* yang dirancang khusus untuk mengenali dan menganalisis pola visual yang kompleks. CNN memiliki kemampuan untuk secara otomatis mengekstraksi fitur penting dari citra medis, seperti tekstur, kontras, dan bentuk abnormal yang mungkin menunjukkan adanya tumor. Dengan kemampuan ini, CNN dapat menggantikan sebagian besar proses manual yang dilakukan oleh manusia, sehingga mengurangi potensi kesalahan, mempercepat proses diagnosis, dan meningkatkan akurasi hasil. Selain itu, CNN juga dapat dioptimalkan untuk bekerja pada berbagai jenis data citra, termasuk citra MRI, yang merupakan salah satu modalitas utama dalam deteksi tumor otak.

Penelitian ini bertujuan untuk mengembangkan model CNN yang mampu mendeteksi tumor otak dengan tingkat akurasi yang tinggi berdasarkan citra MRI. Untuk mencapai tujuan ini, penelitian dilakukan melalui beberapa tahap utama, yaitu pengumpulan data, *preprocessing* citra, pelatihan model, validasi, dan evaluasi kinerja model. Tahap pengumpulan data melibatkan pengambilan citra MRI dari sumber terpercaya, seperti database publik atau institusi medis, dengan memastikan keberagaman jenis tumor yang terwakili dalam dataset. Selanjutnya, *preprocessing* citra dilakukan untuk meningkatkan kualitas data dan memastikan konsistensi dalam input model, termasuk langkah-langkah seperti normalisasi intensitas piksel, resizing citra ke ukuran standar, dan augmentasi data untuk memperkaya variasi dalam dataset.

Proses pelatihan model melibatkan penggunaan CNN dengan arsitektur yang dirancang khusus untuk tugas klasifikasi tumor otak. Model ini akan dilatih menggunakan data latih yang telah diproses sebelumnya, dengan optimasi parameter dilakukan untuk mencapai kinerja terbaik. Untuk mengevaluasi model, metrik-metrik utama seperti akurasi, sensitivitas (*recall*), *precision*, dan *f1-score* akan digunakan. Akurasi mengukur proporsi prediksi yang benar, sensitivitas menunjukkan kemampuan model dalam mendeteksi tumor dengan benar, *precision* mengukur proporsi prediksi tumor yang benar dari

seluruh prediksi tumor, sedangkan *f1-score* digunakan untuk memberikan gambaran keseimbangan antara *precision* dan sensitivitas (*recall*) dalam mendeteksi tumor. *F1-score* sangat relevan dalam kasus ini karena memperhitungkan ketidakseimbangan data, yang sering terjadi pada dataset medis di mana jumlah citra tumor lebih sedikit dibandingkan citra normal.

Dengan pendekatan ini, penelitian ini diharapkan dapat menghasilkan model yang tidak hanya andal secara teknis tetapi juga dapat diterapkan secara praktis dalam mendukung keputusan klinis. Selain itu, hasil dari penelitian ini diharapkan dapat memberikan kontribusi yang signifikan dalam upaya mempercepat proses diagnosis tumor otak, meningkatkan akurasi deteksi, dan pada akhirnya membantu pasien mendapatkan penanganan yang lebih baik. Model yang dikembangkan juga memiliki potensi untuk diterapkan pada modalitas pencitraan lainnya dan diintegrasikan ke dalam sistem klinis untuk mendukung tenaga medis di berbagai fasilitas kesehatan.

2 Tinjauan Pustaka

Pada bagian ini mencakup penelitian dan konsep-konsep utama yang mendasari pengembangan model Convolutional Neural Network (CNN) untuk deteksi tumor otak berdasarkan citra MRI. Dalam bagian ini, akan dijelaskan beberapa topik utama, termasuk pengolahan citra medis, jaringan saraf konvolusional, aplikasi kecerdasan buatan dalam diagnosis medis, serta evaluasi kinerja model.

2.1 Tumor Otak

Tumor otak adalah pertumbuhan sel abnormal di dalam atau di sekitar struktur otak. Tumor ini dapat dikategorikan menjadi dua jenis utama, yaitu tumor otak primer yang berasal langsung dari jaringan otak atau struktur di sekitarnya, seperti meninges atau saraf kranial, dan tumor otak sekunder (metastasis) yang merupakan penyebaran kanker dari bagian tubuh lain ke otak. Berdasarkan tingkat keganasan, tumor otak juga dapat diklasifikasikan menjadi tumor jinak, seperti meningioma dan schwannoma, yang tumbuh secara lambat dan biasanya tidak menyebar ke jaringan lain, serta tumor ganas, seperti *glioblastoma multiforme* (GBM), yang bersifat agresif dan memiliki potensi menyebar dengan cepat.

Gejala klinis yang ditimbulkan oleh tumor otak sangat bervariasi tergantung pada ukuran, lokasi, dan jenis tumor. Beberapa gejala umum meliputi sakit kepala yang cenderung lebih parah di pagi hari atau memburuk dengan aktivitas fisik, kejang yang sering menjadi gejala awal, gangguan neurologis seperti kelemahan, kesulitan berbicara, atau perubahan penglihatan, serta gangguan kognitif seperti penurunan daya ingat atau perubahan perilaku. Untuk diagnosis, prosedur yang umum dilakukan meliputi penggunaan *Magnetic Resonance Imaging* (MRI) yang memberikan detail anatomi otak yang sangat baik, *Computed Tomography* (CT) untuk evaluasi awal, terutama pada kondisi darurat, dan biopsi untuk menentukan jenis serta tingkat keganasan tumor.

Pengobatan tumor otak bergantung pada jenis, lokasi, dan ukuran tumor, serta kondisi kesehatan pasien secara keseluruhan. Metode pengobatan yang umum meliputi pembedahan untuk mengangkat tumor sebanyak mungkin tanpa merusak jaringan otak sehat, radioterapi yang menggunakan sinar radiasi untuk membunuh sel tumor yang tersisa, kemoterapi yang menggunakan obat untuk menghambat pertumbuhan atau menghancurkan sel kanker, serta terapi target yang menggunakan obat yang secara spesifik menargetkan molekul tertentu pada tumor. Tantangan dalam deteksi dan pengobatan tumor otak meliputi diagnosis dini yang sulit dilakukan karena gejala sering kali muncul setelah tumor mencapai ukuran tertentu, kompleksitas struktur otak yang membuat operasi berisiko, serta tingkat kekambuhan yang tinggi pada tumor ganas seperti glioblastoma.

2.2 Pengolahan Citra Medis

Pengolahan citra medis adalah bidang yang menggunakan teknik-teknik pemrosesan citra untuk menganalisis dan meningkatkan interpretasi citra yang dihasilkan oleh perangkat medis seperti *Magnetic Resonance Imaging* (MRI), *Computed Tomography* (CT), X-ray, dan ultrasonografi. Proses ini bertujuan untuk membantu dokter dalam diagnosis, perencanaan pengobatan, dan evaluasi terapi. Pengolahan citra medis terdiri dari berbagai langkah, yang masing-masing memiliki peran penting dalam menghasilkan data yang dapat diandalkan untuk analisis lebih lanjut.

Tahap awal dalam pengolahan citra medis adalah *preprocessing*, yang bertujuan untuk meningkatkan kualitas citra dengan mengurangi *noise*, meningkatkan kontras, dan memastikan konsistensi data. Noise reduction dilakukan untuk menghilangkan gangguan yang mungkin ada pada citra, seperti *noise* Gaussian atau speckle, yang dapat mengaburkan detail penting. Normalisasi digunakan untuk menstandarkan nilai piksel dalam kisaran tertentu, sehingga konsistensi antara citra yang berbeda dapat terjaga. Histogram *equalization* adalah teknik lain yang digunakan untuk meningkatkan kontras citra, sehingga fitur-fitur penting lebih mudah diidentifikasi.

Langkah berikutnya adalah segmentasi citra, yang bertujuan untuk membagi citra menjadi beberapa wilayah atau objek yang lebih kecil untuk analisis spesifik. Segmentasi sangat penting dalam deteksi tumor otak, karena memungkinkan isolasi area tumor dari jaringan otak sehat. Teknik segmentasi meliputi *thresholding*, yang memisahkan objek berdasarkan intensitas piksel; *region growing*, yang mengelompokkan piksel berdasarkan kesamaan nilai intensitas; serta *edge detection*, yang menggunakan algoritma seperti Sobel, Canny, atau Laplacian untuk mengidentifikasi batas-batas objek.

Ekstraksi fitur merupakan tahap berikutnya, di mana informasi penting dari citra, seperti bentuk, tekstur, atau intensitas, diambil untuk digunakan dalam analisis lebih lanjut. Fitur geometri seperti dimensi, perimeter, dan area objek digunakan untuk menganalisis ukuran dan bentuk tumor. Sementara itu, fitur tekstur dianalisis menggunakan metode seperti *Gray-Level Co-occurrence Matrix* (GLCM) untuk mengidentifikasi pola-pola tertentu dalam citra yang dapat membantu membedakan antara jaringan sehat dan tumor.

Setelah fitur diekstraksi, tahap akhir adalah klasifikasi, di mana citra diberi label berdasarkan fitur yang telah diidentifikasi. Algoritma yang sering digunakan dalam klasifikasi citra medis meliputi *Support Vector Machine* (SVM), *Random Forest*, dan *Neural Networks*. Algoritma-algoritma ini dirancang untuk mengenali pola-pola kompleks dalam data dan membuat prediksi yang akurat mengenai kategori citra, seperti tumor otak jinak atau ganas.

Pengolahan citra medis menghadapi beberapa tantangan, termasuk kualitas citra yang sering kali rendah akibat noise atau artefak, volume data yang besar yang membutuhkan kapasitas komputasi tinggi, dan kebutuhan validasi klinis yang ketat untuk memastikan bahwa hasil yang diperoleh dapat diandalkan dalam praktik medis. Namun, dengan perkembangan teknologi, banyak tantangan ini dapat diatasi melalui algoritma yang lebih canggih dan perangkat keras yang lebih kuat.

2.3 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN), adalah jenis jaringan saraf tiruan yang dirancang khusus untuk menangani data dalam bentuk grid, seperti citra. CNN telah menjadi teknologi unggulan dalam berbagai aplikasi yang melibatkan analisis citra, termasuk pengenalan pola, segmentasi, dan klasifikasi. Struktur CNN terdiri dari beberapa komponen utama yang bekerja secara berurutan untuk mengekstraksi fitur dari citra dan melakukan prediksi.

Komponen pertama dalam CNN adalah lapisan konvolusi, yang bertugas untuk mengekstraksi fitur dari citra masukan. Operasi konvolusi menggunakan filter atau kernel untuk mendeteksi pola-pola lokal, seperti tepi, sudut, atau tekstur. Lapisan konvolusi menghasilkan peta fitur yang merepresentasikan keberadaan pola-pola tersebut pada berbagai lokasi dalam citra. Fungsi aktivasi, seperti *Rectified Linear Unit* (ReLU), diterapkan setelah konvolusi untuk memperkenalkan non-linearitas, yang memungkinkan jaringan untuk mempelajari hubungan kompleks antara fitur-fitur tersebut.

Setelah lapisan konvolusi, *pooling layer* digunakan untuk mengurangi dimensi peta fitur sambil mempertahankan informasi penting. *Pooling* dapat dilakukan menggunakan teknik seperti *max pooling*, yang mengambil nilai maksimum dari setiap wilayah kecil dalam peta fitur, atau *average pooling*, yang menghitung rata-rata nilai dalam wilayah tersebut. Pengurangan dimensi ini membantu mengurangi jumlah parameter dalam jaringan, sehingga mempercepat proses pelatihan dan mengurangi risiko *overfitting*.

Setelah beberapa lapisan konvolusi dan *pooling*, peta fitur yang dihasilkan diratakan menjadi vektor satu dimensi melalui proses *flattening*. Vektor ini kemudian diberikan ke lapisan *fully connected*, yang berfungsi untuk menggabungkan informasi dari seluruh fitur yang diekstraksi dan membuat prediksi akhir. Lapisan *fully connected* sering kali diikuti oleh fungsi aktivasi *softmax* untuk menghasilkan probabilitas bagi setiap kelas dalam tugas klasifikasi.

CNN memiliki keunggulan dalam mempelajari representasi hierarkis dari data visual. Lapisan awal biasanya menangkap fitur sederhana seperti tepi dan tekstur, sementara lapisan yang lebih dalam

menangkap pola yang lebih kompleks seperti bentuk atau objek lengkap. Hal ini membuat CNN sangat efektif dalam tugas-tugas yang melibatkan data visual.

Penggunaan CNN dalam analisis citra medis telah menghasilkan kemajuan signifikan dalam diagnosis dan pengobatan berbagai penyakit, termasuk kanker, penyakit kardiovaskular, dan gangguan neurologis. Namun, implementasi CNN menghadapi tantangan seperti kebutuhan akan data pelatihan yang besar, biaya komputasi yang tinggi, dan interpretabilitas model yang terbatas. Meskipun demikian, dengan dukungan perangkat keras yang lebih kuat dan algoritma yang terus berkembang, CNN terus menjadi alat yang semakin andal dalam analisis citra medis.

2.4 *Artificial Intelligence* dalam Diagnosis Medis

Aplikasi *Artificial Intelligence* (AI) dalam diagnosis medis telah membawa revolusi dalam cara dokter menganalisis data dan membuat keputusan. Dengan kemampuan untuk memproses data dalam jumlah besar dan mendeteksi pola yang sulit dikenali oleh manusia, AI telah membantu meningkatkan akurasi dan efisiensi diagnosis di berbagai bidang medis. Salah satu area utama penerapan AI adalah dalam analisis citra medis, di mana algoritma *deep learning* seperti CNN digunakan untuk mendeteksi dan mengklasifikasikan penyakit berdasarkan citra yang dihasilkan oleh perangkat medis.

Dalam deteksi tumor otak, AI telah digunakan untuk mengidentifikasi tumor secara otomatis dari citra MRI dan CT. Model berbasis CNN dapat mengekstrak fitur penting dari citra untuk membedakan antara tumor jinak dan ganas, serta memprediksi ukuran dan lokasi tumor dengan akurasi tinggi. Selain itu, AI juga digunakan dalam segmentasi tumor, yang memungkinkan dokter untuk memisahkan area tumor dari jaringan sehat secara lebih akurat, mendukung perencanaan pengobatan yang lebih efektif.

Di luar deteksi tumor, AI telah diterapkan dalam diagnosis penyakit lain, seperti pneumonia, kanker payudara, dan penyakit kardiovaskular. Dalam analisis citra X-ray, AI mampu mendeteksi pneumonia dengan sensitivitas yang lebih tinggi dibandingkan dokter umum. Dalam bidang onkologi, AI digunakan untuk menganalisis biopsi digital dan mendeteksi tanda-tanda kanker pada tahap awal, meningkatkan peluang keberhasilan pengobatan.

AI juga berperan penting dalam personalisasi pengobatan. Dengan menganalisis data genomik dan citra medis, algoritma AI dapat membantu merancang terapi yang disesuaikan dengan karakteristik unik pasien, meningkatkan efektivitas dan mengurangi efek samping. Misalnya, dalam radioterapi, AI digunakan untuk merencanakan dosis radiasi yang optimal berdasarkan distribusi tumor yang terdeteksi pada citra medis.

Namun, meskipun potensi AI dalam diagnosis medis sangat besar, terdapat tantangan yang harus diatasi. Salah satunya adalah kebutuhan akan dataset yang besar dan berkualitas tinggi untuk melatih model. Kurangnya data yang representatif dapat menyebabkan bias dalam prediksi, yang dapat memengaruhi keakuratan diagnosis. Selain itu, interpretabilitas model AI menjadi perhatian, karena keputusan yang dibuat oleh algoritma sering kali sulit dijelaskan kepada dokter dan pasien. Regulasi dan persetujuan klinis juga menjadi hambatan, karena model AI harus diuji secara ketat sebelum dapat digunakan dalam praktik medis.

Dengan perkembangan teknologi, AI diperkirakan akan terus berkembang dan memainkan peran yang semakin besar dalam diagnosis medis. Dengan menggabungkan kemampuan manusia dan AI, diharapkan bahwa diagnosis dan pengobatan penyakit dapat dilakukan dengan lebih cepat, akurat, dan efisien, memberikan manfaat besar bagi pasien dan sistem perawatan kesehatan secara keseluruhan.

2.5 Evaluasi Kinerja Model

Evaluasi kinerja model adalah langkah penting untuk menilai efektivitas dan keandalan model dalam menyelesaikan tugas tertentu. Dalam konteks deteksi tumor otak menggunakan CNN, evaluasi dilakukan dengan menggunakan berbagai metrik seperti akurasi, sensitivitas (*recall*), precision, dan *f1-score*. Metrik-metrik ini memberikan gambaran menyeluruh tentang performa model, baik dalam mendeteksi kasus positif maupun dalam menghindari kesalahan deteksi.

Confusion matrix merupakan alat dasar yang digunakan untuk mengevaluasi kinerja model klasifikasi. Matriks ini menunjukkan jumlah prediksi yang benar (*True Positive* dan *True Negative*) serta kesalahan prediksi (*False Positive* dan *False Negative*). Dari *confusion matrix*, metrik seperti akurasi dapat dihitung sebagai proporsi dari total prediksi yang benar terhadap keseluruhan prediksi. *Precision* digunakan untuk mengukur persentase prediksi positif yang benar, sedangkan *recall* mengukur

kemampuan model dalam mendeteksi semua kasus positif. *F1-score*, yang merupakan rata-rata harmonik antara *precision* dan *recall*, digunakan untuk menyeimbangkan kedua metrik ini, terutama ketika terdapat ketidakseimbangan kelas dalam data.

Evaluasi model juga melibatkan analisis kesalahan untuk mengidentifikasi pola dalam prediksi yang salah. Kesalahan prediksi dapat disebabkan oleh faktor seperti kualitas data yang rendah, ketidakseimbangan kelas, atau kompleksitas fitur yang sulit dipelajari oleh model. Dengan memahami sumber kesalahan ini, pengembang dapat melakukan perbaikan pada model atau data, seperti meningkatkan preprocessing, menggunakan data augmentasi, atau mengadopsi arsitektur yang lebih kompleks.

Pada akhirnya, evaluasi kinerja model tidak hanya memberikan wawasan tentang efektivitas model, tetapi juga membantu memastikan bahwa model dapat diandalkan dalam aplikasi klinis. Model yang menunjukkan nilai tinggi pada metrik evaluasi diharapkan mampu memberikan hasil yang konsisten dan akurat, sehingga dapat digunakan untuk mendukung diagnosis dan pengobatan tumor otak secara efektif.

3 Hasil

Pada bagian ini, akan dijelaskan hasil dari proses pengembangan dan evaluasi model Convolutional Neural Network (CNN) untuk mendeteksi tumor otak berdasarkan dataset citra MRI otak.

3.1 Dataset

Dataset yang digunakan terdiri dari dua kelas, yaitu Brain Tumor dan Healthy, dengan data berupa citra MRI otak yang telah melalui beberapa tahap preprocessing. Proses preprocessing meliputi:

1. **Resize:** Mengubah ukuran citra menjadi 256x256 piksel untuk memastikan keseragaman ukuran input ke model.
2. **Augmentasi Data:**
 - **Horizontal Flip:** Membalik citra secara horizontal dengan probabilitas 50%.
 - **Vertical Flip:** Membalik citra secara vertikal dengan probabilitas 50%.
 - **Rotation:** Memutar citra dengan sudut acak hingga 30 derajat.
3. **Normalisasi:** Menstandarkan nilai piksel berdasarkan mean dan standar deviasi dari dataset ImageNet untuk mempercepat konvergensi model.

Berikut adalah beberapa sampel citra dari data latih setelah melalui proses augmentasi dan transformasi:




Figure 1: Beberapa sampel citra dari data latih

Setiap citra diberi label sesuai dengan kategori:

- **Brain Tumor:** Citra yang menunjukkan adanya tumor pada otak.
- **Healthy:** Citra yang menunjukkan otak yang sehat tanpa indikasi tumor.

3.2 Arsitektur Model CNN

Arsitektur model *Convolutional Neural Network* (CNN) yang dirancang terdiri dari beberapa lapisan yang dirancang untuk mengekstrak fitur dari citra MRI otak secara bertahap, hingga dapat mengklasifikasikan citra tersebut ke dalam kategori *Brain Tumor* atau *Healthy*. Struktur lengkap model adalah sebagai berikut:

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 8, 254, 254]	224
Conv2d-2	[-1, 16, 125, 125]	1,168
Conv2d-3	[-1, 32, 60, 60]	4,640
Conv2d-4	[-1, 64, 28, 28]	18,496
Linear-5	[-1, 100]	1,254,500
Linear-6	[-1, 2]	202
Total params: 1,279,230		
Trainable params: 1,279,230		
Non-trainable params: 0		
Input size (MB): 0.75		
Forward/backward pass size (MB): 7.11		
Params size (MB): 4.88		
Estimated Total Size (MB): 12.74		

Figure 2: Arsitektur model CNN

Berikut adalah penjelasan setiap lapisan pada model CNN:

1. *Convolutional Layers:*

- **Conv1:** Lapisan konvolusi dengan kernel 3x3, menghasilkan 8 fitur.
 - Dimensi output: 8x254x254
 - Diikuti oleh fungsi aktivasi ReLU dan MaxPooling dengan kernel 2x2, menghasilkan dimensi: 8x127x127.
- **Conv2:** Lapisan konvolusi dengan kernel 3x3, menghasilkan 16 fitur.
 - Dimensi output: 16x125x125
 - Diikuti oleh fungsi aktivasi ReLU dan MaxPooling dengan kernel 2x2, menghasilkan dimensi: 16x62x62.
- **Conv3:** Lapisan konvolusi dengan kernel 3x3, menghasilkan 32 fitur.
 - Dimensi output: 32x60x60
 - Diikuti oleh fungsi aktivasi ReLU dan MaxPooling dengan kernel 2x2, menghasilkan dimensi: 32x30x30.
- **Conv4:** Lapisan konvolusi dengan kernel 3x3, menghasilkan 64 fitur.
 - Dimensi output: 64x28x28
 - Diikuti oleh fungsi aktivasi ReLU dan MaxPooling dengan kernel 2x2, menghasilkan dimensi: 64x14x14.

2. **Flatten Layer:** Data hasil lapisan konvolusi terakhir diubah menjadi vektor 1 dimensi dengan panjang: $64 \times 14 \times 14 = 12544$.

3. *Fully Connected Layers*:

- **FC1:** Lapisan fully connected dengan 100 neuron.
 - Fungsi aktivasi ReLU diterapkan.
 - Dropout sebesar 25% diterapkan untuk mencegah overfitting.
- **FC2:** Lapisan *fully connected* dengan 2 neuron, masing-masing mewakili kelas *Brain Tumor* dan *Healthy*.
 - Fungsi aktivasi *softmax* digunakan untuk mengubah output menjadi probabilitas untuk setiap kelas.
- **Output Layer:** Probabilitas untuk dua kelas, yaitu *Brain Tumor* dan *Healthy*.

3.3 Proses Pelatihan

Proses pelatihan dilakukan untuk melatih model agar dapat memprediksi kategori citra dengan akurasi tinggi. Berikut adalah langkah-langkah dan parameter yang digunakan selama pelatihan:

3.3.1 Parameter Pelatihan

1. **Algoritma Optimisasi:** *Adam Optimizer*, dipilih karena kemampuannya yang adaptif untuk menyesuaikan *learning rate* selama pelatihan.
2. **Learning Rate:** Dimulai dari 0.0003 dengan penyesuaian otomatis menggunakan ReduceLROnPlateau.
3. **Loss Function:** *Negative Log-Likelihood Loss* (NLLLoss), yang cocok untuk tugas klasifikasi multi-kelas dengan output berupa probabilitas.
4. **Scheduler:** ReduceLROnPlateau dengan:
 - Mode: 'min'
 - Faktor Penurunan: 0.5
 - Patience: 20 epoch tanpa perbaikan.
5. **Jumlah Epoch:** Model dilatih selama 60 epoch untuk memastikan konvergensi.
6. **Batch Size:** 64, untuk efisiensi memori GPU selama pelatihan.

3.3.2 Tahapan Pelatihan

1. **Forward Pass:** Data masukan dari data loader diteruskan melalui semua lapisan model untuk menghasilkan output probabilitas.
2. **Loss Calculation:** Loss dihitung menggunakan *Negative Log-Likelihood Loss* (NLLLoss) untuk membandingkan prediksi dengan label ground truth.
3. **Backward Pass:** Gradien dihitung untuk setiap parameter menggunakan *backpropagation*.
4. **Parameter Update:** Parameter model diperbarui menggunakan *Adam Optimizer*.
5. **Validasi:** Setelah setiap epoch, model dievaluasi pada data validasi untuk menghitung *loss* dan akurasi validasi.
6. **Learning Rate Adjustment:** Jika *loss* validasi tidak membaik setelah 20 epoch, *learning rate* dikurangi sebesar 50%.
7. **Penyimpanan Model Terbaik:** Bobot model terbaik disimpan berdasarkan nilai *loss* validasi terendah.




Figure 3: Grafik *loss* dan akurasi pada data latih dan validasi

3.3.3 Hasil Pelatihan

Selama pelatihan, grafik berikut menunjukkan konvergensi *loss* dan peningkatan akurasi pada data latih dan validasi:

- **Grafik *Loss*:** Menunjukkan penurunan *loss* baik pada data latih maupun validasi selama proses pelatihan, yang mengindikasikan konvergensi model.
- **Grafik Akurasi:** Menunjukkan peningkatan akurasi pada data latih dan validasi, yang mengindikasikan kemampuan model untuk generalisasi pada data yang tidak terlihat.

Berdasarkan grafik, model mencapai nilai *loss* terendah pada epoch ke 60. Bobot model pada epoch tersebut disimpan sebagai model final untuk evaluasi lebih lanjut.

3.4 Evaluasi Model

Evaluasi model dilakukan pada data validasi yang tidak digunakan dalam proses pelatihan untuk mengukur performa akhir. Berikut adalah hasil evaluasi model:

Classification report menunjukkan metrik seperti *precision*, *recall*, dan *f1-score* untuk setiap kelas, serta akurasi keseluruhan model. Hasil evaluasi menunjukkan bahwa model mencapai akurasi sebesar 98% pada data validasi, dengan rincian sebagai berikut:

	precision	recall	f1-score	support
0.0	0.98	0.98	0.98	503
1.0	0.97	0.97	0.97	418
accuracy			0.98	921
macro avg	0.98	0.98	0.98	921
weighted avg	0.98	0.98	0.98	921

Figure 4: *Classification report*

Selain itu, *confusion matrix* juga digunakan untuk memberikan gambaran lebih rinci terkait distribusi prediksi model pada masing-masing kelas. Berikut adalah *confusion matrix* hasil evaluasi model:




Figure 5: *Confusion matrix*

Secara keseluruhan, model menunjukkan performa yang sangat baik dalam mendeteksi tumor otak, dengan nilai precision dan recall yang tinggi pada kedua kelas. Evaluasi ini mengindikasikan bahwa model dapat diandalkan untuk tugas klasifikasi tumor otak berbasis citra MRI.

4 Kesimpulan

Penelitian ini berhasil menunjukkan bahwa model *Convolutional Neural Network* (CNN) memiliki potensi besar dalam mendeteksi tumor otak dengan akurasi yang tinggi. Melalui serangkaian proses pelatihan dan evaluasi, model ini mampu mengenali pola-pola kompleks dalam citra MRI, memberikan prediksi yang akurat untuk membedakan antara tumor jinak, tumor ganas, dan jaringan otak sehat. Penggunaan metrik evaluasi, seperti akurasi, sensitivitas (*recall*), *precision* dan *f1-score*, memberikan gambaran yang jelas tentang performa model dalam mendeteksi tumor otak.

Hasil penelitian menunjukkan bahwa integrasi teknologi kecerdasan buatan dalam analisis citra medis dapat mengatasi banyak keterbatasan dalam metode manual, seperti waktu analisis yang lama dan potensi kesalahan manusia. Selain itu, model CNN yang dikembangkan juga menunjukkan kemampuan untuk bekerja secara efisien pada data yang kompleks, sehingga dapat diandalkan untuk mendukung diagnosis klinis.

Namun, penelitian ini juga menyadari adanya beberapa tantangan, seperti kebutuhan akan dataset yang lebih besar dan representatif, serta pentingnya validasi klinis sebelum penerapan luas. Dengan adanya pengembangan lebih lanjut, model ini diharapkan dapat menjadi alat yang efektif untuk mendukung tenaga medis dalam mendeteksi tumor otak secara cepat dan akurat, sehingga meningkatkan kualitas pelayanan kesehatan dan hasil pengobatan bagi pasien.

References

- [1] Ostrom, Q. T., Cioffi, G., Gittleman, H., Patil, N., Waite, K., Kruchko, C., & Barnholtz-Sloan, J. S. (2019). CBTRUS Statistical Report: Primary Brain and Other Central Nervous System Tumors Diagnosed in the United States. *Neuro-Oncology*, 21(Suppl 5), v1–v100.
- [2] Louis, D. N., Perry, A., Reifenberger, G., von Deimling, A., Figarella-Branger, D., Cavenee, W. K., ... & Ellison, D. W. (2016). The 2016 World Health Organization Classification of Tumors of the Central Nervous System: A summary. *Acta Neuropathologica*, 131(6), 803–820.
- [3] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... & van Ginneken, B. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88.
- [4] Dougherty, G. (2020). Advances in Biomedical Image Processing. *Springer International Publishing*.
- [5] Esteva, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., ... & Dean, J. (2019). A guide to deep learning in healthcare. *Nature Medicine*, 25(1), 24–29.

A Kode Program

Kode program model CNN dapat diakses di repositori GitHub berikut:

<https://github.com/alethat/MachineLearningTasks/tree/main/EndTermTask>